

Organoid-FL: 类器官检测联邦学习平台

项目进展汇报 v3

2026 年 6 月

目录

- 1 问题与背景
- 2 踩坑总结
- 3 MultiOrg 实验结果
- 4 鼠肝实验规划
- 5 联邦学习
- 6 总结

问题与背景

什么是类器官？

类器官 (Organoid)

- 体外培养的微型器官（肺、肠、脑等）
- 用于药物筛选、个性化医疗、疾病建模
- 显微镜下成像后需人工计数和形态分析
- 通量低、主观性强、跨实验室一致性差

核心痛点

类器官图像分析依赖人工，成为药物研发管线的瓶颈。自动化检测是解决方案，但面临多个技术挑战。

技术挑战

- **超大图**：6K×5.7K 像素
- **密集小目标**：单图数百个 organoid
- **标注噪声**：多标注者不一致
- **数据分散**：多中心数据无法共享

为什么需要联邦学习？

数据隐私与数据分散的矛盾

- 多家医院/实验室各自有类器官图像数据
- 涉及患者来源 → 无法集中共享
- 单中心数据量不足 → 模型泛化性差
- 各中心培养条件/成像设备不同 → 数据分布异构 (non-IID)

联邦学习 (Federated Learning)

- 数据不动，模型动：各中心本地训练，只上传模型参数
- 数据不动，知识动：聚合后的全局模型吸收所有中心的知识
- 数据不动，推理动：全局模型下发给各中心本地推理

FL + Organoid 是未被探索的交叉方向

踩坑总结

踩坑总结：数据集层面

铁律：使用任何新数据集前，必须先查官方文档

- MultiOrg 标注 JSON 使用 napari 的 $(row, col) = (y, x)$ 坐标系，不是常规 (x, y)
- 论文用单类 organoid (Normal/Macros 只是培养条件，不是检测类别)
- 论文用 512 patch + 丢弃边界 bbox + 全图滑动窗口推理，不是 640 patch 上直接评估

三个根本性错误 → 100 epoch mAP=0

	错误做法	正确做法（论文方法）
类别	2 类 (Normal/Macros)	单类 organoid
边界 bbox	裁剪到 patch 边缘	丢弃边界 bbox
评估	patch 上直接评估	全图滑动窗口推理

坐标系错误 → 标注越界

napari $[y,x]$ 格式被当 $[x,y]$ 读 → 标注 y 最大 5845 > 图片高 5720，交换后 x 最大 5845 < 宽 6385

踩坑总结：代码层面

2026-06-28 系统审计发现 7 个 bug

文件	Bug	影响	严重性
multiorg_sam2.py	mask_iou_cropped offset x/y 交换	所有 mask mAP 数值错误	Critical
multiorg_sam2.py	mask_iou() 死代 码	无	Minor
multiorg_sam2.py	load_sam2 临时 文件不清理	磁盘泄漏	Medium
multiorg_tiling_v3.py	PIL l;16→numpy segfault	Macros 类崩溃	Critical
prepare_sam2_pseudo.py	cache return 跳过 所有后续图	数据缺失	Critical
prepare_sam2_pseudo.py	fallback mask 全 图分配	OOM 风险	Medium
prepare_sam2_pseudo.py	instance 编号错位	训练读错 mask	Critical

教训

• 写完脚本必须端到端验证 不能只过 py_compile

踩坑总结：实验设计层面

val 集 drop_boundary 导致 mAP 暴跌 15pp

- train 用 drop_boundary=True (干净信号)
- val 也用 drop_boundary=True → 把模型正确检测变 false positive
- 正确做法：val 必须 clip 到 patch 边缘 (保留所有 GT)

GT 标注质量决定微调策略

	鼠肝	MultiOrg
标注类型	红色折线 (精确轮廓)	4 点多边形 (位置标注)
SAM2 微调	有效 (F1=93.9%)	有害 (mask mAP -4pp)
正确做法	mask supervision	位置 prompt only

核心教训

用粗糙 GT 微调精确 SAM2 = 负优化。GT 质量决定 supervision 方式。

MultiOrg 实验结果

标注者选择对评估的影响

同一模型，不同标注者评估

标注者	Instances	mAP@0.5	mAP@0.5:0.95	Recall
t0 (初始)	6465	66.9%	32.6%	60.2%
t1_A (二次)	3950	70.5%	38.7%	64.8%
t1_B (最精准)	4112	78.9%	53.9%	72.3%

关键发现

- 标注者选择可造成 **12pp mAP@0.5 差异** (66.9% vs 78.9%)
- t0 噪声最大 (6465 instances, 含误标); t1_B 最精简 (4112 instances)
- 评估方法论和模型本身一样重要——噪声标注会严重低估模型能力

MultiOrg 检测精度 vs SOTA

mAP@0.5 对比

配置	mAP@0.5	vs SOTA
Faster R-CNN (论文)	60.7%	-7.4pp
RTMDet (论文)	61.6%	-6.5pp
YOLOv3 (论文)	64.6%	-3.5pp
SSD (SOTA)	68.1%	—
YOLOv12s patch 级	78.1%	+10.0pp
RF-DETR small SAHI 全图	77.13%	+9.0pp
YOLOv12s SAHI 全图	68.8%	+0.7pp

结论

- Patch 级超 SOTA +10.0pp, SAHI 全图超 SOTA +0.7pp
- RF-DETR NMS-free 结构在密集 organoid 上有结构性优势
- 距 80% 门槛还差 2-3pp, 瓶颈是数据量 (600 张)

SAM2 分割实验：自蒸馏方案

问题：4 点多边形 GT 太粗糙

MultiOrg 标注只标 4 个点（位置），不是精确轮廓。直接用 4 点多边形微调 SAM2 = 负优化（mask mAP -4pp）。

方案 A：自蒸馏（Self-Distillation）

- ① GT 4 点多边形 → bbox（位置 prompt）
- ② SAM2 zero-shot 用 bbox 做 prompt → 伪 mask（精确轮廓）
- ③ 伪 mask 作为微调 supervision（替代粗糙的 4 点多边形）

训练结果（5 epoch, 3060 12GB）

Epoch	Train IoU	Val IoU	Val Dice	耗时
1	0.8437	0.8419	0.9074	70min
3	0.8646	0.8594	0.9181	70min
5	0.8814	0.8720	0.9255	70min

SAM2 对照实验结果

全量 55 张测试, mask IoU bug 修复后

配置	bbox mAP50	mask mAP50	F1	FP
Zero-shot SAM2	待跑	待跑	—	—
Finetuned v2 (4 点 GT)	待跑	待跑	—	—
Finetuned pseudo	77.13%	75.89%	43.9%	11553

形态学过滤无效 (复现鼠肝结论)

Filter	mAP50	Prec	Rec	F1
baseline	77.1%	28.6%	93.6%	43.9%
conf $\geq$ 0.4	75.1%	43.8%	88.2%	58.5%
conf $\geq$ 0.5	70.5%	60.2%	79.0%	68.4%
circ/solid/ar	砍 FP < 2%, 无效			

结论

形态学过滤对 MultiOrg 无效。conf 是唯一有效维度, 但阈值高了砍 recall。瓶颈在检测器, 不在后处理。

鼠肝实验规划

鼠肝实验：已有基础

数据

- Batch 1: 10 对图 (2592×1944, 4X), 23 个类器官
- Batch 2: 10 对图 (4000×3000, 不同相机), 41 个类器官
- 红色折线轮廓标注 (精确轮廓, 非 4 点)
- OpenCV 提取轮廓 → YOLO 格式 bbox

Batch 1 结果

- RF-DETR few-shot (8 张, 1ep)
- + zero-shot SAM2 分割
- **F1 = 93.9%**
- SAM2 mask 和人工红线格式一致

Batch 2 域偏移测试

Batch 1 模型 → Batch 2 推理 → F1=0% (完全失败)。根因：不同相机/光照/对比度，不是分辨率问题。

鼠肝实验：为什么值得做？

鼠肝 vs MultiOrg 对比

	鼠肝	MultiOrg
标注质量	红色折线（精确轮廓）	4 点多边形（位置）
SAM2 微调	有效（F1=93.9%）	有害（-4pp）
形态学过滤	有效（conf+circ）	无效
数据量	20 张（few-shot）	411 张
域偏移	有（batch 1→2 F1=0）	无

鼠肝实验的独特价值

- 精确 GT：折线轮廓 → SAM2 微调有效 → 可以做 mask 级评估
- 域偏移：不同实验室/相机/光照 → FL 的天然场景
- Few-shot：数据少 → FL 价值更大（单中心不够训）
- 已有 pipeline：RF-DETR + SAM2 + 形态学过滤已验证

鼠肝实验：三阶段计划

Phase 1: 单中心精度验证 (1-2 周)

- ① Batch 1 (10 张) 训练 RF-DETR few-shot + SAM2 微调 (已有 $F1=93.9\%$)
- ② Batch 2 (10 张) 作为独立 test set → 模拟跨域泛化
- ③ 对比 zero-shot SAM2 vs finetuned SAM2 的 mask 质量
- ④ 关键验证: 精确 GT 微调 SAM2 是否真有增益 (vs MultiOrg 的负优化)

Phase 2: 跨域泛化 + 图像预处理标准化 (2-3 周)

- ① Batch 1 → Batch 2 域偏移量化 (当前 $F1=0\%$)
- ② 图像预处理标准化模块:
 - 分辨率归一化 (到固定 m/px)
 - 对比度归一化 (CLAHE)
 - 背景扣除
 - 位深统一 (16bit→8bit)
- ③ 验证预处理后跨域 $F1$ 是否提升

鼠肝实验：FL 场景设计

Phase 3：联邦学习实验（3-4 周）

① Client 划分：

- Client A: Batch 1 (2592×1944, 4X 相机)
- Client B: Batch 2 (4000×3000, 不同相机)
- Client C: 数据增强生成 (模拟第三中心)

② Non-IID 设计：

- 分辨率异质 (不同 m/px)
- 光照异质 (不同对比度/亮度)
- 标注密度异质 (不同 organoid 数量/图)


③ 聚合策略对比：FedAvg vs EWA vs FedProx

④ 评估：mask mAP50 + bbox mAP50 + 跨域 F1

预期贡献

- 首个 FL + 类器官检测的跨域泛化研究
- 图像预处理标准化模块 (多实验室平台的刚需)
- EWA Effective Interval 在跨模态场景的验证

鼠肝实验：技术路线图



- Phase 1 已有基础 (F1=93.9%), 重点验证 SAM2 微调增益
- Phase 2 解决域偏移 (batch 1→2 F1=0%), 预处理标准化是关键
- Phase 3 FL 实验, 鼠肝的精确 GT 让 mask 级评估有意义

联邦学习

EWA 熵加权聚合策略

核心思想

传统 FedAvg 按样本量均匀加权，忽略客户端模型质量差异。

EWA 用验证集熵作为信号，给更好的客户端更高权重：

$$w_c = \frac{\exp(-H_c/\alpha)}{\sum_{c'} \exp(-H_{c'}/\alpha)}$$

其中 H_c 是客户端 c 在验证集上的预测熵， α 是温度参数。

EWA Effective Interval 理论

- IID：质量差异小 $\rightarrow$ EWA 退化 $\rightarrow$ 无优势
- 适度异质：差异可区分 $\rightarrow$ EWA 最优 $\rightarrow +1.4\sim 1.5pp$
- 极端异质：信号噪声大 $\rightarrow +1.1pp$

总结

总结

已完成

- ✓ SOTA 全面调研
- ✓ 数据预处理管线 (tiling + 多标注者)
- ✓ 标注 bug 修复 (mAP +26pp)
- ✓ MultiOrg patch 级超 SOTA (+10pp)
- ✓ MultiOrg SAHI 全图超 SOTA (+0.7pp)
- ✓ SAM2 自蒸馏微调 (val IoU 0.87)
- ✓ 代码系统审计 (7 bug 修复)
- ✓ 鼠肝 batch 1 验证 (F1=93.9%)

进行中 / 待完成

- SAM2 对照实验 (zero-shot vs finetuned)
- 鼠肝 Phase 1-3 实验
- 图像预处理标准化模块
- FL + Organoid 系统实验
- 论文撰写 + 专利申请

参考文献 I



Bukas et al. *MultiOrg: A Multi-rater Organoid-detection Dataset*. NeurIPS, 2024.



Tian et al. *YOLOv12: Attention-Centric Real-Time Object Detectors*. arXiv:2502.12524, 2025.



Solawetz et al. *RF-DETR: Real-Time DETection TRansformer*. ICLR, 2026.



Bodla et al. *Soft-NMS – Improving Object Detection with One Line of Code*. ICCV, 2017.



Akyon et al. *Slicing Aided Hyper Inference (SAHI)*. CVPRW, 2022.



Bulten et al. *Overcoming the Limitations of Patch-based Learning to Detect Cancer in Whole Slide Images*. PMC, 2021.



Lu et al. *Thinking with Visual Primitives*. DeepSeek-AI, 2025.



Kirillov et al. *Segment Anything (SAM)*. ICCV, 2023.

Thank You!

Questions & Discussion

`github.com/dechang64/organoid-fl`