

# Organoid-FL: 类器官检测联邦学习平台

## 项目进展汇报 v5

2026 年 7 月

# 目录

- 1 问题与背景
- 2 踩坑总结
- 3 MultiOrg 实验结果
- 4 鼠肝实验规划
- 5 联邦学习
- 6 总结

## 问题与背景

# 什么是类器官？

## 类器官 (Organoid)

- 体外培养的微型器官（肺、肠、脑等）
- 用于药物筛选、个性化医疗、疾病建模
- 显微镜下成像后需人工计数和形态分析
- 通量低、主观性强、跨实验室一致性差

## 核心痛点

类器官图像分析依赖人工，成为药物研发管线的瓶颈。自动化检测是解决方案，但面临多个技术挑战。

## 技术挑战

- **超大图**：6K×5.7K 像素
- **密集小目标**：单图数百个 organoid
- **标注噪声**：多标注者不一致
- **数据分散**：多中心数据无法共享

# 为什么需要联邦学习？

## 数据隐私与数据分散的矛盾

- 多家医院/实验室各自有类器官图像数据
- 涉及患者来源 → 无法集中共享
- 单中心数据量不足 → 模型泛化性差
- 各中心培养条件/成像设备不同 → 数据分布异构 (non-IID)

## 联邦学习 (Federated Learning)

- 数据不动，模型动：各中心本地训练，只上传模型参数
- 数据不动，知识动：聚合后的全局模型吸收所有中心的知识
- 数据不动，推理动：全局模型下发给各中心本地推理

FL + Organoid 是未被探索的交叉方向

## 踩坑总结

# 踩坑总结：数据集层面

## 铁律：使用任何新数据集前，必须先查官方文档

- MultiOrg 标注 JSON 使用 napari 的  $(row, col) = (y, x)$  坐标系，不是常规  $(x, y)$
- 论文用单类 organoid (Normal/Macros 只是培养条件，不是检测类别)
- 论文用 512 patch + 丢弃边界 bbox + 全图滑动窗口推理，不是 640 patch 上直接评估

## 三个根本性错误 → 100 epoch mAP=0

|         | 错误做法                | 正确做法（论文方法）  |
|---------|---------------------|-------------|
| 类别      | 2 类 (Normal/Macros) | 单类 organoid |
| 边界 bbox | 裁剪到 patch 边缘        | 丢弃边界 bbox   |
| 评估      | patch 上直接评估         | 全图滑动窗口推理    |

## 坐标系错误 → 标注越界

napari  $[y,x]$  格式被当  $[x,y]$  读 → 标注  $y$  最大 5845 > 图片高 5720，交换后  $x$  最大 5845 < 宽 6385

# 踩坑总结：代码层面

2026-06-28 系统审计发现 7 个 bug

| 文件                     | Bug                               | 影响               | 严重性      |
|------------------------|-----------------------------------|------------------|----------|
| multiorg_sam2.py       | mask_iou_cropped<br>offset x/y 交换 | 所有 mask mAP 数值错误 | Critical |
| multiorg_sam2.py       | mask_iou() 死代<br>码                | 无                | Minor    |
| multiorg_sam2.py       | load_sam2 临时<br>文件不清理             | 磁盘泄漏             | Medium   |
| multiorg_tiling_v3.py  | PIL l;16→numpy<br>segfault        | Macros 类崩溃       | Critical |
| prepare_sam2_pseudo.py | cache return 跳过<br>所有后续图          | 数据缺失             | Critical |
| prepare_sam2_pseudo.py | fallback mask 全<br>图分配            | OOM 风险           | Medium   |
| prepare_sam2_pseudo.py | instance 编号错位                     | 训练读错 mask        | Critical |

## 教训

• 写完脚本必须端到端验证 不能只过 py\_compile



# 踩坑总结：实验设计层面

## val 集 drop\_boundary 导致 mAP 暴跌 15pp

- train 用 drop\_boundary=True (干净信号)
- val 也用 drop\_boundary=True → 把模型正确检测变 false positive
- 正确做法：val 必须 clip 到 patch 边缘 (保留所有 GT)

## GT 标注质量决定微调策略

|         | 鼠肝               | MultiOrg           |
|---------|------------------|--------------------|
| 标注类型    | 红色折线 (精确轮廓)      | 4 点多边形 (位置标注)      |
| SAM2 微调 | 有效 (F1=93.9%)    | 有害 (mask mAP -4pp) |
| 正确做法    | mask supervision | 位置 prompt only     |

## 核心教训

用粗糙 GT 微调精确 SAM2 = 负优化。GT 质量决定 supervision 方式。

## MultiOrg 实验结果

# 标注者选择对评估的影响

## 同一模型，不同标注者评估

| 标注者        | Instances | mAP@0.5      | mAP@0.5:0.95 | Recall       |
|------------|-----------|--------------|--------------|--------------|
| t0 (初始)    | 6465      | 66.9%        | 32.6%        | 60.2%        |
| t1_A (二次)  | 3950      | 70.5%        | 38.7%        | 64.8%        |
| t1_B (最精准) | 4112      | <b>78.9%</b> | <b>53.9%</b> | <b>72.3%</b> |

## 关键发现

- 标注者选择可造成 **12pp mAP@0.5 差异** (66.9% vs 78.9%)
- t0 噪声最大 (6465 instances, 含误标); t1\_B 最精简 (4112 instances)
- 评估方法论和模型本身一样重要——噪声标注会严重低估模型能力

# MultiOrg 检测精度 vs SOTA

## mAP@0.5 对比 (t1\_b 标注)

| 配置                               | mAP@0.5      | vs SOTA       |
|----------------------------------|--------------|---------------|
| Faster R-CNN (论文)                | 68.4%        | -5.5pp        |
| YOLOv3 (论文)                      | 70.3%        | -3.6pp        |
| RTMDet (论文)                      | 63.2%        | -10.7pp       |
| <b>SSD (论文 SOTA)</b>             | <b>73.9%</b> | —             |
| YOLOv12s patch 级                 | 78.1%        | +4.2pp        |
| RF-DETR SAHI+Soft-NMS            | 77.15%       | +3.3pp        |
| <b>RF-DETR ensemble baseline</b> | <b>77.8%</b> | <b>+3.9pp</b> |

## 结论

- 我们已是 MultiOrg SOTA，超论文最优 SSD +3.9pp
- 论文 2024.10 发表，无后续工作超过我们
- 距 80% 门槛差 2.2pp，瓶颈是数据量（356 张 vs Orga-Dete 4008 张）

# SAM2 分割实验：自蒸馏方案

## 问题：4 点多边形 GT 太粗糙

MultiOrg 标注只标 4 个点（位置），不是精确轮廓。直接用 4 点多边形微调 SAM2 = 负优化（mask mAP -4pp）。

## 方案 A：自蒸馏（Self-Distillation）

- ① GT 4 点多边形 → bbox（位置 prompt）
- ② SAM2 zero-shot 用 bbox 做 prompt → 伪 mask（精确轮廓）
- ③ 伪 mask 作为微调 supervision（替代粗糙的 4 点多边形）

## 训练结果（5 epoch, 3060 12GB）

| Epoch | Train IoU     | Val IoU       | Val Dice      | 耗时    |
|-------|---------------|---------------|---------------|-------|
| 1     | 0.8437        | 0.8419        | 0.9074        | 70min |
| 3     | 0.8646        | 0.8594        | 0.9181        | 70min |
| 5     | <b>0.8814</b> | <b>0.8720</b> | <b>0.9255</b> | 70min |

# SAM2 对照实验结果

全量 55 张测试, mask IoU bug 修复后

| 配置                    | bbox mAP50 | mask mAP50    | F1    | FP    |
|-----------------------|------------|---------------|-------|-------|
| Zero-shot SAM2        | 77.15%     | <b>76.39%</b> | 43.9% | 11553 |
| Finetuned v2 (4 点 GT) | 77.15%     | 75.98%        | 43.9% | 11553 |
| Finetuned pseudo      | 77.13%     | 75.89%        | 43.9% | 11553 |

## 结论: 微调 = 负优化

- bbox mAP50 三者一致 (SAM2 不改检测框)
- mask mAP50: zero-shot 76.39% > finetuned 75.98% > pseudo 75.89%
- 根因: 4 点粗糙 GT 微调精确 SAM2 = 负优化
- 自蒸馏天花板 = zero-shot 本身质量

## FP 抑制全面失败

| 方案                    | 结论            |
|-----------------------|---------------|
| 形态学过滤 (circ/solid/ar) | 砍 FP < 2%, 无效 |

## 鼠肝实验规划

# 鼠肝实验：已有基础

## 数据

- Batch 1: 10 对图 (2592×1944, 4X), 23 个类器官
- Batch 2: 10 对图 (4000×3000, 不同相机), 41 个类器官
- 红色折线轮廓标注 (精确轮廓, 非 4 点)
- OpenCV 提取轮廓 → YOLO 格式 bbox

## Batch 1 结果

- RF-DETR few-shot (8 张, 1ep)
- + zero-shot SAM2 分割
- **F1 = 93.9%**
- SAM2 mask 和人工红线格式一致

## Batch 2 域偏移测试

Batch 1 模型 → Batch 2 推理 → F1=0% (完全失败)。根因：不同相机/光照/对比度，不是分辨率问题。



# 鼠肝实验：为什么值得做？

## 鼠肝 vs MultiOrg 对比

|         | 鼠肝                | MultiOrg   |
|---------|-------------------|------------|
| 标注质量    | 红色折线（精确轮廓）        | 4 点多边形（位置） |
| SAM2 微调 | 有效（F1=93.9%）      | 有害（-4pp）   |
| 形态学过滤   | 有效（conf+circ）     | 无效         |
| 数据量     | 20 张（few-shot）    | 411 张      |
| 域偏移     | 有（batch 1→2 F1=0） | 无          |

## 鼠肝实验的独特价值

- 精确 GT：折线轮廓 → SAM2 微调有效 → 可以做 mask 级评估
- 域偏移：不同实验室/相机/光照 → FL 的天然场景
- Few-shot：数据少 → FL 价值更大（单中心不够训）
- 已有 pipeline：RF-DETR + SAM2 + 形态学过滤已验证

# 鼠肝实验：三阶段计划

## Phase 1: 单中心精度验证 (1-2 周)

- ① Batch 1 (10 张) 训练 RF-DETR few-shot + SAM2 微调 (已有  $F1=93.9\%$ )
- ② Batch 2 (10 张) 作为独立 test set → 模拟跨域泛化
- ③ 对比 zero-shot SAM2 vs finetuned SAM2 的 mask 质量
- ④ 关键验证: 精确 GT 微调 SAM2 是否真有增益 (vs MultiOrg 的负优化)

## Phase 2: 跨域泛化 + 图像预处理标准化 (2-3 周)

- ① Batch 1 → Batch 2 域偏移量化 (当前  $F1=0\%$ )
- ② 图像预处理标准化模块:
  - 分辨率归一化 (到固定  $m/px$ )
  - 对比度归一化 (CLAHE)
  - 背景扣除
  - 位深统一 (16bit→8bit)
- ③ 验证预处理后跨域 F1 是否提升

# 鼠肝实验：FL 场景设计

## Phase 3：联邦学习实验（3-4 周）

### ① Client 划分：

- Client A: Batch 1 (2592×1944, 4X 相机)
- Client B: Batch 2 (4000×3000, 不同相机)
- Client C: 数据增强生成 (模拟第三中心)

### ② Non-IID 设计：

- 分辨率异质 (不同  $m/px$ )
- 光照异质 (不同对比度/亮度)
- 标注密度异质 (不同 organoid 数量/图)


### ③ 聚合策略对比：FedAvg vs EWA vs FedProx

### ④ 评估：mask mAP50 + bbox mAP50 + 跨域 F1

## 预期贡献

- 首个 FL + 类器官检测的跨域泛化研究
- 图像预处理标准化模块 (多实验室平台的刚需)
- EWA Effective Interval 在跨模态场景的验证

# 鼠肝实验：技术路线图



- Phase 1 已有基础 (F1=93.9%), 重点验证 SAM2 微调增益
- Phase 2 解决域偏移 (batch 1→2 F1=0%), 预处理标准化是关键
- Phase 3 FL 实验, 鼠肝的精确 GT 让 mask 级评估有意义

# 联邦学习

# EWA 熵加权聚合策略

## 核心思想

传统 FedAvg 按样本量均匀加权，忽略客户端模型质量差异。

EWA 用验证集熵作为信号，给更好的客户端更高权重：

$$w_c = \frac{\exp(-H_c/\alpha)}{\sum_{c'} \exp(-H_{c'}/\alpha)}$$

其中  $H_c$  是客户端  $c$  在验证集上的预测熵， $\alpha$  是温度参数。

## EWA Effective Interval 理论

- IID：质量差异小  $\rightarrow$  EWA 退化  $\rightarrow$  无优势
- 适度异质：差异可区分  $\rightarrow$  EWA 最优  $\rightarrow +1.4\sim 1.5pp$
- 极端异质：信号噪声大  $\rightarrow +1.1pp$

## 总结

# Ensemble 实验: RF-DETR + YOLOv12

## 三种融合策略结果

| 策略            | mAP50 | mAP50-95 | vs RF-DETR |
|---------------|-------|----------|------------|
| RF-DETR 单模型   | 77.8% | 48.8%    | —          |
| YOLOv12s 单模型  | 62.3% | 37.2%    | −15.5pp    |
| WBF (SOTA 融合) | 63.2% | 38.3%    | −14.5pp    |
| Intersection  | 63.1% | 39.7%    | −14.7pp    |
| Union         | 70.0% | 42.8%    | −7.8pp     |

## 失败原因: YOLOv12s 是严格劣势模型

- YOLO recall 80.4%  $\ll$  RF-DETR 96.2%, 无独有 TP
- Ensemble TP=4745 < RF-DETR TP=4767  $\rightarrow$  YOLO 未补充任何 recall
- WBF 的 T/N 机制反而拉低 RF-DETR 高分 TP 的 score
- 结论: ensemble 需要两个精度接近的模型才能受益



# 全面文献调研: MultiOrg SOTA

## MultiOrg 数据集 SOTA (mAP@0.5, t1\_b)

| 方法                  | 来源               | mAP50        |
|---------------------|------------------|--------------|
| SSD                 | MultiOrg 论文 SOTA | 73.9%        |
| YOLOv3              | MultiOrg 论文      | 70.3%        |
| Faster R-CNN        | MultiOrg 论文      | 68.4%        |
| <b>RF-DETR (我们)</b> | <b>本研究</b>       | <b>77.8%</b> |

## 其他 organoid 数据集 SOTA

| 方法        | mAP50    | 数据集               | 数据量    |
|-----------|----------|-------------------|--------|
| Deliod    | 87.5%    | Intestinal        | —      |
| Orga-Dete | 81.4%    | Lung              | 4008 张 |
| Orga-Dete | 92.5%    | Duodenal          | —      |
| Orga-Dete | 84.4%    | Murine intestinal | —      |
| OrgLine   | N/A (PQ) | Multi-source      | —      |

结论：三模块全面失败，停止该方向

| 配置                                       | mAP50 | vs baseline | 结论        |
|------------------------------------------|-------|-------------|-----------|
| yolo12s baseline                         | 62.3% | —           | 参考        |
| yolo11n + MPCA                           | 44.2% | —           | 容量瓶颈      |
| yolo11n + MPCA + EMASlideLoss            | 44.0% | -0.2pp      | 噪声级       |
| yolo12s + MPCA (random init)             | 43.5% | -18.8pp     | 破坏预训练     |
| yolo12s + MPCA (identity init)           | 43.9% | -18.4pp     | init 不是根因 |
| yolo12s + MPCA (identity) + EMASlideLoss | 44.5% | -17.8pp     | 噪声级       |

## MPCA Identity Init 修复 (commit 0cd3169)

- 问题：Sigmoid 随机初始化  $\approx 0.5 \rightarrow$  特征方差减半  $\rightarrow$  破坏预训练
- 修复：weight=0, bias=5  $\rightarrow \text{sigmoid}(5) \approx 1.0 \rightarrow \text{output} \approx x$  (identity)
- 验证：std ratio 0.50  $\rightarrow$  0.99, 预训练匹配 48.6%  $\rightarrow$  99.2%
- 但 mAP 几乎不变 (+0.38pp) ——init 不是根因

## 模型容量 vs mAP 强相关

| 模型                   | mAP50 |
|----------------------|-------|
| RF-DETR small (32M)  | 77.8% |
| YOLOv12s (9.4M)      | 62.3% |
| YOLOv11n+MPCA (2.6M) | 44.2% |
| YOLOv12s+MPCA (9.6M) | 43.9% |

每 3.5x 参数  $\approx$  +18pp

## 五个根因

- ① 模型容量瓶颈: 2.6M vs 32M
- ② MPCA 架构不兼容: C3k2 vs A2C2f
- ③ 单类检测无增益: 坐标注意力对多类有用
- ④ 数据集差异: 4008 张 vs 411 张
- ⑤ BiFPN 未验证: YAML 不兼容

## 铁律: 乘性 Attention 必须 Identity Init

任何加在预训练模型上的乘性 attention 模块 (SE、CBAM、CA、MPCA), 初始状态必须是 identity, 否则 sigmoid $\approx$ 0.5 会破坏预训练特征。验证方法: output/input std ratio  $\approx$  1.0。

# 总结

## 已完成

- ✓ SOTA 全面调研 (MultiOrg + Orga-Dete + OrgLine)
- ✓ 数据预处理管线 (tiling + 多标注者)
- ✓ 标注 bug 修复 (mAP +26pp)
- ✓ **MultiOrg SOTA: 77.8% (超论文 +3.9pp)**
- ✓ SAM2 三轮实验: 微调 = 负优化确认
- ✓ FP 抑制全面调研: DINOv2/形态学/HNM 均无效
- ✓ Ensemble 实验: WBF/Union/Intersection 全面失败
- ✓ **Orga-Dete 三模块迁移: 全面失败**
- ✓ MPCA Identity Init 铁律发现
- ✓ 鼠肝 batch 1 验证 (F1=93.9%)

## 下一步

- **RF-DETR + SAHI 优化冲 80%**
- yolo12m (20M) 容量升级评估
  - 鼠肝 Phase 1-3 实验
  - 图像预处理标准化模块
  - FL + Organoid 系统实验
  - 论文撰写 + 专利申请

# 参考文献 I



Bukas et al. *MultiOrg: A Multi-rater Organoid-detection Dataset*. NeurIPS, 2024.



Tian et al. *YOLOv12: Attention-Centric Real-Time Object Detectors*. arXiv:2502.12524, 2025.



Solawetz et al. *RF-DETR: Real-Time DETection TRansformer*. ICLR, 2026.



Bodla et al. *Soft-NMS – Improving Object Detection with One Line of Code*. ICCV, 2017.



Akyon et al. *Slicing Aided Hyper Inference (SAHI)*. CVPRW, 2022.



Bulten et al. *Overcoming the Limitations of Patch-based Learning to Detect Cancer in Whole Slide Images*. PMC, 2021.



Lu et al. *Thinking with Visual Primitives*. DeepSeek-AI, 2025.



Kirillov et al. *Segment Anything (SAM)*. ICCV, 2023.



Solovyev et al. *Weighted Boxes Fusion: Ensembling boxes from different object detection models*. IVC, 2021.



Huang et al. *Orga-Dete: An Improved Lightweight Deep Learning Model for Lung Organoid Detection*. Applied Sciences, 2025.



Deng et al. *OrgLine: A versatile pipeline for organoid morphometry using detector-guided prompts*. Cell Reports Methods, 2026.

# Thank You!

Questions & Discussion

`github.com/dechang64/organoid-fl`