

Organoid-FL: 类器官检测联邦学习平台

项目进展汇报 v6

2026 年 7 月

目录

- 1 问题与背景
- 2 踩坑总结
- 3 MultiOrg 实验结果
- 4 鼠肝实验结果
- 5 联邦学习
- 6 总结

问题与背景

什么是类器官？

类器官 (Organoid)

- 体外培养的微型器官（肺、肠、脑等）
- 用于药物筛选、个性化医疗、疾病建模
- 显微镜下成像后需人工计数和形态分析
- 通量低、主观性强、跨实验室一致性差

核心痛点

类器官图像分析依赖人工，成为药物研发管线的瓶颈。自动化检测是解决方案，但面临多个技术挑战。

技术挑战

- **超大图**：6K×5.7K 像素
- **密集小目标**：单图数百个 organoid
- **标注噪声**：多标注者不一致
- **数据分散**：多中心数据无法共享

为什么需要联邦学习？

数据隐私与数据分散的矛盾

- 多家医院/实验室各自有类器官图像数据
- 涉及患者来源 → 无法集中共享
- 单中心数据量不足 → 模型泛化性差
- 各中心培养条件/成像设备不同 → 数据分布异构 (non-IID)

联邦学习 (Federated Learning)

- 数据不动，模型动：各中心本地训练，只上传模型参数
- 数据不动，知识动：聚合后的全局模型吸收所有中心的知识
- 数据不动，推理动：全局模型下发给各中心本地推理

FL + Organoid 是未被探索的交叉方向

踩坑总结

踩坑总结：数据集层面

铁律：使用任何新数据集前，必须先查官方文档

- MultiOrg 标注 JSON 使用 napari 的 $(row, col) = (y, x)$ 坐标系，不是常规 (x, y)
- 论文用单类 organoid (Normal/Macros 只是培养条件，不是检测类别)
- 论文用 512 patch + 丢弃边界 bbox + 全图滑动窗口推理，不是 640 patch 上直接评估

三个根本性错误 → 100 epoch mAP=0

	错误做法	正确做法（论文方法）
类别	2 类 (Normal/Macros)	单类 organoid
边界 bbox	裁剪到 patch 边缘	丢弃边界 bbox
评估	patch 上直接评估	全图滑动窗口推理

坐标系错误 → 标注越界

napari $[y,x]$ 格式被当 $[x,y]$ 读 → 标注 y 最大 5845 > 图片高 5720，交换后 x 最大 5845 < 宽 6385

踩坑总结：代码层面

2026-06-28 系统审计发现 7 个 bug

文件	Bug	影响	严重性
multiorg_sam2.py	mask_iou_cropped offset x/y 交换	所有 mask mAP 数值错误	Critical
multiorg_sam2.py	mask_iou() 死代 码	无	Minor
multiorg_sam2.py	load_sam2 临时 文件不清理	磁盘泄漏	Medium
multiorg_tiling_v3.py	PIL l;16→numpy segfault	Macros 类崩溃	Critical
prepare_sam2_pseudo.py	cache return 跳过 所有后续图	数据缺失	Critical
prepare_sam2_pseudo.py	fallback mask 全 图分配	OOM 风险	Medium
prepare_sam2_pseudo.py	instance 编号错位	训练读错 mask	Critical

教训

• 写完脚本必须端到端验证 不能只过 py_compile

踩坑总结：实验设计层面

val 集 drop_boundary 导致 mAP 暴跌 15pp

- train 用 drop_boundary=True (干净信号)
- val 也用 drop_boundary=True → 把模型正确检测变 false positive
- 正确做法：val 必须 clip 到 patch 边缘 (保留所有 GT)

GT 标注质量决定微调策略

	鼠肝	MultiOrg
标注类型	红色折线 (精确轮廓)	4 点多边形 (位置标注)
SAM2 微调	有效 (F1=93.9%)	有害 (mask mAP -4pp)
正确做法	mask supervision	位置 prompt only

核心教训

用粗糙 GT 微调精确 SAM2 = 负优化。GT 质量决定 supervision 方式。

MultiOrg 实验结果

标注者选择对评估的影响

同一模型，不同标注者评估

标注者	Instances	mAP@0.5	mAP@0.5:0.95	Recall
t0 (初始)	6465	66.9%	32.6%	60.2%
t1_A (二次)	3950	70.5%	38.7%	64.8%
t1_B (最精准)	4112	78.9%	53.9%	72.3%

关键发现

- 标注者选择可造成 **12pp mAP@0.5 差异** (66.9% vs 78.9%)
- t0 噪声最大 (6465 instances, 含误标); t1_B 最精简 (4112 instances)
- 评估方法论和模型本身一样重要——噪声标注会严重低估模型能力

MultiOrg 检测精度 vs SOTA

mAP@0.5 对比 (t1_b 标注)

配置	mAP@0.5	vs SOTA
Faster R-CNN (论文)	68.4%	-5.5pp
YOLOv3 (论文)	70.3%	-3.6pp
RTMDet (论文)	63.2%	-10.7pp
SSD (论文 SOTA)	73.9%	—
YOLOv12s patch 级	78.1%	+4.2pp
RF-DETR SAHI+Soft-NMS	77.15%	+3.3pp
RF-DETR ensemble baseline	77.8%	+3.9pp

结论

- 我们已是 MultiOrg SOTA，超论文最优 SSD +3.9pp
- 论文 2024.10 发表，无后续工作超过我们
- 距 80% 门槛差 2.2pp，瓶颈是数据量（356 张 vs Orga-Dete 4008 张）

SAM2 分割实验：自蒸馏方案

问题：4 点多边形 GT 太粗糙

MultiOrg 标注只标 4 个点（位置），不是精确轮廓。直接用 4 点多边形微调 SAM2 = 负优化（mask mAP -4pp）。

方案 A：自蒸馏（Self-Distillation）

- ① GT 4 点多边形 → bbox（位置 prompt）
- ② SAM2 zero-shot 用 bbox 做 prompt → 伪 mask（精确轮廓）
- ③ 伪 mask 作为微调 supervision（替代粗糙的 4 点多边形）

训练结果（5 epoch, 3060 12GB）

Epoch	Train IoU	Val IoU	Val Dice	耗时
1	0.8437	0.8419	0.9074	70min
3	0.8646	0.8594	0.9181	70min
5	0.8814	0.8720	0.9255	70min

SAM2 对照实验结果

全量 55 张测试, mask IoU bug 修复后

配置	bbox mAP50	mask mAP50	F1	FP
Zero-shot SAM2	77.15%	76.39%	43.9%	11553
Finetuned v2 (4 点 GT)	77.15%	75.98%	43.9%	11553
Finetuned pseudo	77.13%	75.89%	43.9%	11553

结论: 微调 = 负优化

- bbox mAP50 三者一致 (SAM2 不改检测框)
- mask mAP50: zero-shot 76.39% > finetuned 75.98% > pseudo 75.89%
- 根因: 4 点粗糙 GT 微调精确 SAM2 = 负优化
- 自蒸馏天花板 = zero-shot 本身质量

FP 抑制全面失败

方案	结论
形态学过滤 (circ/solid/ar)	砍 FP < 2%, 无效

鼠肝实验结果

鼠肝实验：三批数据

数据概况

批次	张数	分辨率	Organoids	日期
Batch 1	10	2592×1944	23	2026-01
Batch 2	10	2592×1944	23	2026-05
Batch 3	20	4000×3000	40	2026-07
Total	40	2 种分辨率	86	

标注方式

- 红色折线轮廓（精确轮廓）
- OpenCV 提取 → YOLO 格式 bbox
- 三批数据统一格式

SOTA Benchmark

- RF-DETR few-shot + SAM2
- Batch 1: F1=93.9%
- 冬生本地 GPU

鼠肝实验：三方案结果 (YOLOv12n, CPU)

方案 1: 跨域推理 (Batch1 训练 → Batch2/3 推理)

测试集	F1	TP	FP	FN
B1 val (10img)	—	mAP50=99.5%	P=99.6%	R=100%
B2 (10img, 同分辨率)	100%	23	0	0
B3 (20img, 4000×3000)	7.1%	3	42	37

方案 3: 统一训练 (B1+B2 → val + B3 推理)

测试集	mAP50	F1
B1+B2 val (4img)	71.4%	P=61%, R=75%
B3 跨域 (20img)	—	9.4%

方案 2: 联邦学习—未完成

云 VM CPU 限制 (4GB cgroup), 3 节点 × 5 轮 × 10ep 计算量过大。需冬生本地 GPU。

鼠肝实验：关键发现

B1→B2 跨域完美 ($F1=100\%$)

- 同分辨率 2592×1944
- 同设备/光照
- 10 张训练即完美泛化
- 同分布数据不需 FL

B3 是瓶颈 ($F1 < 10\%$)

- 4000×3000 vs 2592×1944
- 分辨率域偏移
- organoid 相对尺寸变化
- FL 真正价值在 B3 场景

三个洞察

- ① 统一训练不如单批: $B1+B2 \text{ mAP50}=71.4\% < B1 \text{ alone } 99.5\%$ — B2 标注质量（折线提取）可能不如 B1
- ② 分辨率标准化是关键: B3 resize 到 2592×1944 后仍 $F1 < 10\%$ — 不只是尺寸，是成像设备差异
- ③ FL 场景设计: B1+B2 同分布（不需要 FL），B3 跨分辨率（FL 有价值）— 真正的 FL 实验需要 B3 独立训练

鼠肝实验：下一步

方案 2 联邦学习（需冬生本地 GPU）

- 3 节点：B1(10 张) / B2(10 张) / B3(20 张)
- 5 轮 FedAvg，每轮 10 local epochs
- 关键验证：FL 聚合后 B3 跨域 F1 是否提升
- 脚本已准备：run_all_experiments.py 2

图像预处理标准化

- B3 跨域失败根因：分辨率 + 成像设备差异
- 方向：分辨率归一化 + CLAHE 对比度归一化
- 目标：B3 经标准化后跨域 F1 > 50%

FL 论文叙事

- B1→B2 F1=100%：同分布不需 FL（对照组）
- B1→B3 F1=7%：跨域需 FL（实验组）
- FL 聚合后预期 F1 提升：验证“数据不动，知识动”

鼠肝实验：FL 场景设计

Phase 3：联邦学习实验（3-4 周）

① Client 划分：

- Client A: Batch 1 (2592×1944, 4X 相机)
- Client B: Batch 2 (4000×3000, 不同相机)
- Client C: 数据增强生成 (模拟第三中心)

② Non-IID 设计：

- 分辨率异质 (不同 m/px)
- 光照异质 (不同对比度/亮度)
- 标注密度异质 (不同 organoid 数量/图)


③ 聚合策略对比：FedAvg vs EWA vs FedProx

④ 评估：mask mAP50 + bbox mAP50 + 跨域 F1

预期贡献

- 首个 FL + 类器官检测的跨域泛化研究
- 图像预处理标准化模块 (多实验室平台的刚需)
- EWA Effective Interval 在跨模态场景的验证

鼠肝实验：技术路线图



- Phase 1 已有基础 (F1=93.9%), 重点验证 SAM2 微调增益
- Phase 2 解决域偏移 (batch 1→2 F1=0%), 预处理标准化是关键
- Phase 3 FL 实验, 鼠肝的精确 GT 让 mask 级评估有意义

联邦学习

EWA 熵加权聚合策略

核心思想

传统 FedAvg 按样本量均匀加权，忽略客户端模型质量差异。

EWA 用验证集熵作为信号，给更好的客户端更高权重：

$$w_c = \frac{\exp(-H_c/\alpha)}{\sum_{c'} \exp(-H_{c'}/\alpha)}$$

其中 H_c 是客户端 c 在验证集上的预测熵， α 是温度参数。

EWA Effective Interval 理论

- IID：质量差异小 → EWA 退化 → 无优势
- 适度异质：差异可区分 → EWA 最优 → +1.4~1.5pp
- 极端异质：信号噪声大 → +1.1pp

总结

Ensemble 实验: RF-DETR + YOLOv12

三种融合策略结果

策略	mAP50	mAP50-95	vs RF-DETR
RF-DETR 单模型	77.8%	48.8%	—
YOLOv12s 单模型	62.3%	37.2%	−15.5pp
WBF (SOTA 融合)	63.2%	38.3%	−14.5pp
Intersection	63.1%	39.7%	−14.7pp
Union	70.0%	42.8%	−7.8pp

失败原因: YOLOv12s 是严格劣势模型

- YOLO recall 80.4% $\ll$ RF-DETR 96.2%, 无独有 TP
- Ensemble TP=4745 < RF-DETR TP=4767 $\rightarrow$ YOLO 未补充任何 recall
- WBF 的 T/N 机制反而拉低 RF-DETR 高分 TP 的 score
- 结论: ensemble 需要两个精度接近的模型才能受益

全面文献调研: MultiOrg SOTA

MultiOrg 数据集 SOTA (mAP@0.5, t1_b)

方法	来源	mAP50
SSD	MultiOrg 论文 SOTA	73.9%
YOLOv3	MultiOrg 论文	70.3%
Faster R-CNN	MultiOrg 论文	68.4%
RF-DETR (我们)	本研究	77.8%

其他 organoid 数据集 SOTA

方法	mAP50	数据集	数据量
Deliod	87.5%	Intestinal	—
Orga-Dete	81.4%	Lung	4008 张
Orga-Dete	92.5%	Duodenal	—
Orga-Dete	84.4%	Murine intestinal	—
OrgLine	N/A (PQ)	Multi-source	—

结论：三模块全面失败，停止该方向

配置	mAP50	vs baseline	结论
yolo12s baseline	62.3%	—	参考
yolo11n + MPCA	44.2%	—	容量瓶颈
yolo11n + MPCA + EMASlideLoss	44.0%	-0.2pp	噪声级
yolo12s + MPCA (random init)	43.5%	-18.8pp	破坏预训练
yolo12s + MPCA (identity init)	43.9%	-18.4pp	init 不是根因
yolo12s + MPCA (identity) + EMASlideLoss	44.5%	-17.8pp	噪声级

MPCA Identity Init 修复 (commit 0cd3169)

- 问题：Sigmoid 随机初始化 $\approx 0.5 \rightarrow$ 特征方差减半 $\rightarrow$ 破坏预训练
- 修复：weight=0, bias=5 $\rightarrow \text{sigmoid}(5) \approx 1.0 \rightarrow \text{output} \approx x$ (identity)
- 验证：std ratio 0.50 $\rightarrow$ 0.99, 预训练匹配 48.6% $\rightarrow$ 99.2%
- 但 mAP 几乎不变 (+0.38pp) ——init 不是根因

模型容量 vs mAP 强相关

模型	mAP50
RF-DETR small (32M)	77.8%
YOLOv12s (9.4M)	62.3%
YOLOv11n+MPCA (2.6M)	44.2%
YOLOv12s+MPCA (9.6M)	43.9%

每 3.5x 参数 $\approx$ +18pp

五个根因

- ① 模型容量瓶颈：2.6M vs 32M
- ② MPCA 架构不兼容：C3k2 vs A2C2f
- ③ 单类检测无增益：坐标注意力对多类有用
- ④ 数据集差异：4008 张 vs 411 张
- ⑤ BiFPN 未验证：YAML 不兼容

铁律：乘性 Attention 必须 Identity Init

任何加在预训练模型上的乘性 attention 模块 (SE、CBAM、CA、MPCA)，初始状态必须是 identity，否则 sigmoid $\approx$ 0.5 会破坏预训练特征。验证方法：output/input std ratio $\approx$ 1.0。

已完成

- ✓ SOTA 全面调研 (MultiOrg + Orga-Dete + OrgLine)
- ✓ 数据预处理管线 (tiling + 多标注者)
- ✓ 标注 bug 修复 (mAP +26pp)
- ✓ **MultiOrg SOTA: 77.8% (超论文 +3.9pp)**
- ✓ SAM2 三轮实验: 微调 = 负优化确认
- ✓ FP 抑制全面调研: DINOv2/形态学/HNM 均无效
- ✓ Ensemble 实验: WBF/Union/Intersection 全面失败
- ✓ **Orga-Dete 三模块迁移: 全面失败**
- ✓ MPCA Identity Init 铁律发现
- ✓ 鼠肝 batch 1 验证 (F1=93.9%)
- ✓ **鼠肝三批数据标注提取 (40 张/86 organoids)**

下一步

- **鼠肝方案 2 FL (需本地 GPU)**
- 图像预处理标准化 (B3 跨域)
 - MultiOrg RF-DETR + SAHI 冲 80%
 - FL + Organoid 系统实验
 - 论文撰写 + 专利申请

参考文献 I

-  Bukas et al. *MultiOrg: A Multi-rater Organoid-detection Dataset*. NeurIPS, 2024.
-  Tian et al. *YOLOv12: Attention-Centric Real-Time Object Detectors*. arXiv:2502.12524, 2025.
-  Solawetz et al. *RF-DETR: Real-Time DETection TRansformer*. ICLR, 2026.
-  Bodla et al. *Soft-NMS – Improving Object Detection with One Line of Code*. ICCV, 2017.
-  Akyon et al. *Slicing Aided Hyper Inference (SAHI)*. CVPRW, 2022.
-  Bulten et al. *Overcoming the Limitations of Patch-based Learning to Detect Cancer in Whole Slide Images*. PMC, 2021.
-  Lu et al. *Thinking with Visual Primitives*. DeepSeek-AI, 2025.
-  Kirillov et al. *Segment Anything (SAM)*. ICCV, 2023.
-  Solovyev et al. *Weighted Boxes Fusion: Ensembling boxes from different object detection models*. IVC, 2021.
-  Huang et al. *Orga-Dete: An Improved Lightweight Deep Learning Model for Lung Organoid Detection*. Applied Sciences, 2025.



Deng et al. *OrgLine: A versatile pipeline for organoid morphometry using detector-guided prompts*. Cell Reports Methods, 2026.

Thank You!

Questions & Discussion

`github.com/dechang64/organoid-fl`