

Organoid-FL: 类器官检测联邦学习平台

项目进展汇报 v9

2026 年 7 月

目录

- 1 问题与背景
- 2 踩坑总结
- 3 Intestinal Organoid 实验（最早）
- 4 MultiOrg 实验结果
- 5 鼠肝实验结果
- 6 鼠肝 v2: B2 图片反序 Bug
- 7 鼠肝 v2: 实验设计
- 8 MultiOrg 扩展实验
- 9 联邦学习
- 10 视觉原语方案
- 11 CTM 持续思考实验
- 12 视觉原语文献调研
- 13 Phase 8 小波实验结果
- 14 Phase 9 Slot Attention 结果
- 15 Phase 11 SupCon + C4 闭环
- 16 总结

问题与背景

什么是类器官？

类器官 (Organoid)

- 体外培养的微型器官（肺、肠、脑等）
- 用于药物筛选、个性化医疗、疾病建模
- 显微镜下成像后需人工计数和形态分析
- 通量低、主观性强、跨实验室一致性差

核心痛点

类器官图像分析依赖人工，成为药物研发管线的瓶颈。自动化检测是解决方案，但面临多个技术挑战。

技术挑战

- **超大图**：6K×5.7K 像素
- **密集小目标**：单图数百个 organoid
- **标注噪声**：多标注者不一致
- **数据分散**：多中心数据无法共享

为什么需要联邦学习？

数据隐私与数据分散的矛盾

- 多家医院/实验室各自有类器官图像数据
- 涉及患者来源 → 无法集中共享
- 单中心数据量不足 → 模型泛化性差
- 各中心培养条件/成像设备不同 → 数据分布异构 (non-IID)

联邦学习 (Federated Learning)

- 数据不动，模型动：各中心本地训练，只上传模型参数
- 数据不动，知识动：聚合后的全局模型吸收所有中心的知识
- 数据不动，推理动：全局模型下发给各中心本地推理

FL + Organoid 是未被探索的交叉方向

踩坑总结

踩坑总结：数据集层面

铁律：使用任何新数据集前，必须先查官方文档

- MultiOrg 标注 JSON 使用 napari 的 $(\text{row}, \text{col}) = (y, x)$ 坐标系，不是常规 (x, y)
- 论文用单类 organoid (Normal/Macros 只是培养条件，不是检测类别)
- 论文用 512 patch + 丢弃边界 bbox + 全图滑动窗口推理，不是 640 patch 上直接评估

三个根本性错误 → 100 epoch mAP=0

	错误做法	正确做法（论文方法）
类别	2 类 (Normal/Macros)	单类 organoid
边界 bbox	裁剪到 patch 边缘	丢弃边界 bbox
评估	patch 上直接评估	全图滑动窗口推理

坐标系错误 → 标注越界

napari $[y, x]$ 格式被当 $[x, y]$ 读 → 标注 y 最大 5845 > 图片高 5720，交换后 x 最大 5845 < 宽 6385

踩坑总结：代码层面

2026-06-28 系统审计发现 7 个 bug

文件	Bug	影响	严重性
multiorg_sam2.py	mask_iou_cropped offset x/y 交换	所有 mask mAP 数值错误	Critical
multiorg_sam2.py	mask_iou() 死代 码	无	Minor
multiorg_sam2.py	load_sam2 临时 文件不清理	磁盘泄漏	Medium
multiorg_tiling_v3.py	PIL l;16→numpy segfault	Macros 类崩溃	Critical
prepare_sam2_pseudo.py	cache return 跳过 所有后续图	数据缺失	Critical
prepare_sam2_pseudo.py	fallback mask 全 图分配	OOM 风险	Medium
prepare_sam2_pseudo.py	instance 编号错位	训练读错 mask	Critical

教训

• 写完脚本必须端到端验证 不能只过 py_compile

踩坑总结：实验设计层面

val 集 drop_boundary 导致 mAP 暴跌 15pp

- train 用 drop_boundary=True (干净信号)
- val 也用 drop_boundary=True → 把模型正确检测变 false positive
- 正确做法：val 必须 clip 到 patch 边缘 (保留所有 GT)

GT 标注质量决定微调策略

	鼠肝	MultiOrg
标注类型	红色折线 (精确轮廓)	4 点多边形 (位置标注)
SAM2 微调	有效 (F1=93.9%)	有害 (mask mAP -4pp)
正确做法	mask supervision	位置 prompt only

核心教训

用粗糙 GT 微调精确 SAM2 = 负优化。GT 质量决定 supervision 方式。

Intestinal Organoid 实验 (最早)

Intestinal Organoid: 最早的类器官实验 (2026-06)

Deliod 数据集

- 肠道类器官 (intestinal organoid) 检测数据集
- Deliod 论文 SOTA: YOLOv8s/1088/300ep → mAP50=85.7%
- 关键发现: imgsz=1088 (非 640) 是高分辨率检测的关键

我们的实验结果

配置	mAP50	mAP50-95	vs Deliod	备注
yolo12n/1088	86.7%	—	+1.0pp	代差红利
yolo12s+freebies	88.1%	62.1%	+2.4pp	best=ep57
yolo12s+freebies v2	88.4%	62.2%	+2.7pp	close_mosaic 时序问题
yolo12m/896	—	—	—	20.2M 参数, 训练中

超 SOTA: YOLOv12 + freebies

copy_paste=1.0, mixup=0.15,
label_smoothing=0.1, cos_lr, close_mosaic=15
88.1% > Deliod 87.5% (+0.6pp)

失败实验

SAHl: -11pp; TTA: +0pp; 下采样: -8pp

MultiOrg 实验结果

标注者选择对评估的影响

同一模型，不同标注者评估

标注者	Instances	mAP@0.5	mAP@0.5:0.95	Recall
t0 (初始)	6465	66.9%	32.6%	60.2%
t1_A (二次)	3950	70.5%	38.7%	64.8%
t1_B (最精准)	4112	78.9%	53.9%	72.3%

关键发现

- 标注者选择可造成 **12pp mAP@0.5 差异** (66.9% vs 78.9%)
- t0 噪声最大 (6465 instances, 含误标); t1_B 最精简 (4112 instances)
- 评估方法论和模型本身一样重要——噪声标注会严重低估模型能力

MultiOrg 检测精度 vs SOTA

mAP@0.5 对比 (t1_b 标注)

配置	mAP@0.5	vs SOTA
Faster R-CNN (论文)	68.4%	-5.5pp
YOLOv3 (论文)	70.3%	-3.6pp
RTMDet (论文)	63.2%	-10.7pp
SSD (论文 SOTA)	73.9%	—
YOLOv12s patch 级	78.1%	+4.2pp
RF-DETR SAHI+Soft-NMS	77.15%	+3.3pp
RF-DETR ensemble baseline	77.8%	+3.9pp

结论

- 我们已是 MultiOrg SOTA，超论文最优 SSD +3.9pp
- 论文 2024.10 发表，无后续工作超过我们
- 距 80% 门槛差 2.2pp，瓶颈是数据量（356 张 vs Orga-Dete 4008 张）

SAM2 分割实验：自蒸馏方案

问题：4 点多边形 GT 太粗糙

MultiOrg 标注只标 4 个点（位置），不是精确轮廓。直接用 4 点多边形微调 SAM2 = 负优化（mask mAP -4pp）。

方案 A：自蒸馏（Self-Distillation）

- ① GT 4 点多边形 → bbox（位置 prompt）
- ② SAM2 zero-shot 用 bbox 做 prompt → 伪 mask（精确轮廓）
- ③ 伪 mask 作为微调 supervision（替代粗糙的 4 点多边形）

训练结果（5 epoch, 3060 12GB）

Epoch	Train IoU	Val IoU	Val Dice	耗时
1	0.8437	0.8419	0.9074	70min
3	0.8646	0.8594	0.9181	70min
5	0.8814	0.8720	0.9255	70min

SAM2 对照实验结果

全量 55 张测试, mask IoU bug 修复后

配置	bbox mAP50	mask mAP50	F1	FP
Zero-shot SAM2	77.15%	76.39%	43.9%	11553
Finetuned v2 (4 点 GT)	77.15%	75.98%	43.9%	11553
Finetuned pseudo	77.13%	75.89%	43.9%	11553

结论: 微调 = 负优化

- bbox mAP50 三者一致 (SAM2 不改检测框)
- mask mAP50: zero-shot 76.39% > finetuned 75.98% > pseudo 75.89%
- 根因: 4 点粗糙 GT 微调精确 SAM2 = 负优化
- 自蒸馏天花板 = zero-shot 本身质量

FP 抑制全面失败

方案	结论
形态学过滤 (circ/solid/ar)	砍 FP < 2%, 无效

鼠肝实验结果

鼠肝实验：三批数据

数据概况

批次	张数	分辨率	Organoids	日期
Batch 1	10	2592×1944	23	2026-01
Batch 2	10	2592×1944	23	2026-05
Batch 3	20	4000×3000	40	2026-07
Total	40	2 种分辨率	86	

标注方式

- 红色折线轮廓（精确轮廓）
- OpenCV 提取 → YOLO 格式 bbox
- 三批数据统一格式

SOTA Benchmark

- RF-DETR few-shot + SAM2
- Batch 1: F1=**93.9%**
- 冬生本地 GPU

鼠肝 Batch 1: 最早实验结果 (2026-06)

实验设计: RF-DETR few-shot + SAM2 zero-shot

- Batch 1 (10 张, 2592×1944, 2026-01) → 6 train + 2 test
- RF-DETR Small (COCO) + SAM2 zero-shot (bbox prompt)

检测结果 (RF-DETR bbox)

指标	Batch 1 test
TP	7
FP	0
FN	0
Precision	1.00
Recall	1.00
F1	1.00

分割结果 (SAM2 mask)

指标	Batch 1 test
mask F1	93.9%
mask IoU (TP)	0.872

意义

RF-DETR + SAM2 管线可行。红色折线标注 → SAM2 zero-shot 即可高精度。

鼠肝实验：三方案结果 (YOLOv12n, CPU)

方案 1: 跨域推理 (Batch1 训练 → Batch2/3 推理)

测试集	F1	TP	FP	FN
B1 val (10img)	—	mAP50= 99.5%	P=99.6%	R=100%
B2 (10img, 同分辨率)	100%	23	0	0
B3 (20img, 4000×3000)	7.1%	3	42	37

方案 3: 统一训练 (B1+B2 → val + B3 推理)

测试集	mAP50	F1
B1+B2 val (4img)	71.4%	P=61%, R=75%
B3 跨域 (20img)	—	9.4%

鼠肝 FL: Baseline + 集中式上界

统一 val_set 评估 (9 张混合: B1×3+B2×3+B3×3)

节点	训练图	imgsz	mAP50	mAP50-95	P	R
B1 独立	7	640	0.311	0.211	0.49	0.39
B2 独立	7	640	0.520	0.346	0.99	0.44
B3 独立	17	640	0.015	0.004	0.05	0.17
B3 独立 (E9)	17	1280	0.051	0.013	0.004	0.61
集中式	31	640	0.746	0.589	0.99	0.72
集中式 (E11)	31	1280	0.703	0.557	0.85	0.67

B3 独立训练完全失败

- @640: mAP50=0.015, P=0.05
- @1280: mAP50=0.051, P=0.004
- R 涨 (0.17→0.61) 但分类失败
- imgsz 不是根因

集中式 @1280 反而更差

- 0.746 → 0.703 (-0.043)
- 小数据 + 高分辨率 = 过拟合
- 640 已足够, 1280 有害

鼠肝 FL: B3 数据特征分析

B2 vs B3 标注框大小对比

指标	B2 (2592×1944)	B3 (4000×3000)
框宽均值	790px	223px
框高均值	791px	220px
框最大	2021×1659	517×471
@640px 框宽中位数	161.5px	33.1px
@640px 框面积中位数	33918px ²	1337px ²
极小框 (<1% 面积)	0%	87.5%

B3 organoid 物理尺寸小 (可能不同放大倍数)

- B3 的 organoid 原图 200px, resize 到 640 后仅 33px —YOLO P5 感受野 32px, 信号极弱
- B3@1280 后 66px 一能看到目标 (R 涨), 但 bbox 里背景占比高, 分类信号被淹没 (P=0.004)
- bbox 对不规则类器官只能参考定位, 不能做分类判断

鼠肝 FL: 顺序链式实验矩阵 (E4-E10)

10 round × 10 ep/round, soft gate=EWA 加权

实验	Gate	Order	mAP50	mAP50-95	P	说明
E4	none	b1→b2→b3	0.360	0.130	—	权重退化
E5	hard	b1→b2→b3	0.321	0.162	—	R7 冻结
E6	soft	b1→b2→b3	0.506	0.298	—	持续学习
E7	hard	b3→b2→b1	0.687	0.249	0.005	P 虚高
E8	local	b1→b2→b3	0.564	0.227	—	R3 冻结
E10	soft	b1→b2→b3	0.444	0.169	0.005	B3@1280
集中式	—	—	0.746	0.589	0.99	上界

FL vs 集中式

- E6(soft)=0.506 B2 独立 =0.520
- FL 没有明显优势
- 集中式 0.746 是真正上界

E7/E10 的 P=0.005 假象

- "全检测" 模式: R=0.78 但 FP 暴增
- B3 训练不稳定: mAP50 在 0.01-0.57 间波动
- 33px 目标信号弱 → 训练随机性大

鼠肝 FL: bbox 范式到天花板

三个铁证

- ❶ **imgsz 不是根因**: B3@1280 mAP50=0.051 (vs @640 的 0.015), 依然失败
- ❷ **集中式 @1280 反而更差** (-0.043pp): 小数据 + 高分辨率 = 过拟合更严重
- ❸ **E10 全程 P=0.005**: 分类完全失败, mAP50=0.44 是"全检测"假象

根因分析

- B3 organoid 200px 塞进 bbox, bbox 大部分是背景
- 提高 imgsz → 看到更多细节 **但引入更多背景噪声**
- 分类信号始终被背景淹没—**bbox 范式结构性瓶颈**
- 集中式能成功是因为 B2 大目标的梯度补强了 B3 小目标
- FL 是 round 级参数平均, 不是 step 级梯度混合 → B3 偏掉的参数拖低全局

鼠肝 FL: B3 在 E6(soft) 中的不稳定性

E6 每轮 B3 训练后 mAP50

Round	B3 mAP50	全局 mAP50	B3 > 全局?	说明
R4	0.010	—	拖累	B3 几乎归零
R5	0.510	—	贡献	B3 突然学到
R8	0.018	—	拖累	又归零
R9	0.524	—	贡献	又学到

B3 学习极不稳定—33px 目标信号弱导致训练随机性大

- 好的时候 B3 从 B2 参数迁移受益 (R5/R9: mAP50>0.5)
- 坏的时候 B3 把模型带偏 (R4/R8: mAP50<0.02)
- FL 聚合的是 round 级参数, 不是 step 级梯度—B3 偏掉的参数和 B2 好参数平均 = 拖低全局

鼠肝实验： bbox 范式总结与方向转向

bbox 范式实验全部完成

实验	结论
B1→B2 跨域推理	F1=100% (同分布不需 FL)
B1→B3 跨域推理	F1=7% (分辨率域偏移)
E4-E8 顺序链式 FL	E6(soft) 最优 0.506
E9 B3@1280 独立	mAP50=0.051 (依然失败)
E10 FL B3@1280	P=0.005 分类失败
E11 集中式 @1280	反而更差 (-0.043pp)

结论： bbox 范式到天花板

bbox 对不规则类器官只能参考定位，不能做分类判断。提高 imgsz / SAHI / FL 聚合权重均无法突破。

方向转向：视觉原语框架

bbox → SAM2 mask → 形态学特征 (不受像素尺度影响) → FL 聚合 primitive 分布

鼠肝 v2: B2 图片反序 Bug

踩坑：B2 图片反序 → 训练 mAP=0

铁律：图片重命名必须通过 annotations.json 映射，不能按排序索引

- 鼠肝 v2 实验中 B2 训练 loss=15.4 (B1/B3 仅 6.9)，mAP=0
- 标签内容正确（和 annotations.json 一致），但图片重命名时反序了
- image_00.jpg 实际是 image_09 的图 → 正确标签配在错误图片上

诊断过程

步骤	脚本	结果
MD5 对比	check_pairing.py	B1/B2 同名图不同 → 图片没问题
标签验证	verify_labels.py	标签 → annotations.json 全匹配
extract 配对	verify_labels.py	0/10 正确（排序索引配对）
像素相似度	check_image_naming.py	B2 全部反序 (0/10)

根因

标注图 微信图片 _xxx.jpg vs 原图 image_00.jpg，排序方向相反 → 按索引配对全错。

B2 修复前后对比

修复前（图片反序）

- 初始 loss = 15.4 (B1/B3 = 6.9)
- 16 epoch 后 loss = 11.1 (几乎不降)
- val mAP50 = 0.011
- test F1 = 0.00
- 模型学到“全抑制”: n_det=0

修复后（图片正序）

- ep0 val mAP50 = 0.555
- ep1 val mAP50 = 0.794
- ep8 best mAP50-95 = 0.675
- ep20 final mAP50 = 0.812
- 正常收敛曲线

诊断脚本链

脚本	检查内容
check_pairing.py	图片 MD5 + 标注框像素统计
verify_labels.py	annotations.json bbox vs YOLO label 对比
check_image_naming.py	images/ vs annotated/ 像素相似度 → 找到根因

教训：训练 loss 异常高（2x 于同类）= 数据配对问题的信号

鼠肝 v2: 实验设计

鼠肝 v2: 14 实验矩阵

数据分配 (独立 train/val/test)

批次	张数	分辨率	Train	Val	Test	Fewshot
B1	10	2592×1944	6	2	2	3
B2	10	4000×3000	6	2	2	3
B3	20	4000×3000	12	4	4	3
Central	40	混合	24	8	—	—

Step 1: Baseline+Ceiling (4)

- B1/B2/B3 独立训练
- Central 集中式上界
- RF-DETR Small, COCO 预训练

Step 2: 跨域迁移 (4)

- B1→B2/B3 zeroshot
- B1→B2/B3 fewshot (3-shot)
- 传统 CV (Otsu) 对照
- SAM2 分割

Step 3: 联邦学习 (6)

- F1: none gate, b1→b2→b3
- F2: soft gate (EWA)
- F3: hard gate, b1→b2→b3
- F4: hard gate, b3→b2→b1

鼠肝 v2: 模型与训练参数

Baseline: RF-DETR Small (NMS-free Transformer)

	B1	B2	B3
Resolution	544	768	768
Batch size	4	1	1
Grad accum	1	1	1
Epochs	20	20	20
Early stop	patience=10	patience=10	patience=10

FL: YOLOv12n (轻量级, 3-client 顺序链式)

- 10 rounds $\times$ 10 local epochs/round
- imgsz=640, batch=8, workers=0 (Windows)
- Gate: none / soft (EWA) / hard (w_local=0 or 1)
- 统一 val set = B1/val (公平比较, EWA 信号基于 B1 val)

v1 $\rightarrow$ v2 关键改进

独立 test set; RF-DETR 替代 YOLOv12n; 14 实验全覆盖

鼠肝 v2: Baseline & Ceiling (test set F1)

RF-DETR Small, COCO 预训练, 独立 test set

模型	训练量	TP	FP	FN	P	R	F1	val mAP50
B1	6 张	4	0	0	1.00	1.00	1.00	1.000
B2	6 张	6	3	0	0.67	1.00	0.80	0.818
B3	12 张	6	4	0	0.60	1.00	0.75	0.881
Central	24 张	15	11	1	0.58	0.94	0.71	0.872

B2 修复前后对比

- 修复前: F1=**0.00**, mAP=0.011
- 修复后: F1=**0.80**, mAP=0.818
- Central 也受益: 0.54→0.71

观察

- B1 完美 (2592×1944, 大目标)
- B2/B3 精度略低 (4000×3000, 小目标)
- Central 合并数据反而不如 B1 单独

鼠肝 v2: 跨域迁移 (B1→B2/B3)

B1 checkpoint → B2/B3 test set

目标	模式	TP	FP	FN	P	R	F1
B2	Full (6 张训练)	6	3	0	0.67	1.00	0.80
B2	Zeroshot (直接推理)	1	2	5	0.33	0.17	0.22
B2	Fewshot (3-shot)	6	1	0	0.86	1.00	0.92
B3	Full (12 张训练)	6	4	0	0.60	1.00	0.75
B3	Zeroshot (直接推理)	0	10	6	0.00	0.00	0.00
B3	Fewshot (3-shot)	5	4	1	0.56	0.83	0.67

关键发现

- **B2 fewshot F1=0.92 > B2 full F1=0.80** —3-shot 微调优于从零训练!
- B3 zeroshot F1=0.00 —完全失败 (域偏移大)
- B2 zeroshot F1=0.22 —部分成功 (域偏移较小)
- Few-shot 是跨域迁移的有效策略

鼠肝 v2: 传统 CV vs RF-DETR vs SAM2


三种方法对比 (test set F1)

Batch	方法	F1	P	R
B1	Traditional (Otsu)	0.00	0.00	0.00
B1	RF-DETR	1.00	1.00	1.00
B1	SAM2 (bbox-guided)	1.00	1.00	1.00
B2	Traditional (Otsu)	0.00	0.00	0.00
B2	RF-DETR	0.80	0.67	1.00
B2	SAM2 (fewshot)	0.92	0.86	1.00
B3	Traditional (Otsu)	0.00	0.00	0.00
B3	RF-DETR	0.75	0.60	1.00
B3	SAM2 (fewshot)	0.67	0.56	0.83


结论

传统 CV (Otsu 阈值分割) 完全无效。RF-DETR 是有效的检测方案。SAM2 bbox-guided 分割 F1 = RF-DETR bbox F1 (不增不减检测, 只做分割)。


鼠肝 v2: SAM2 绿色 mask 可视化



B1 Full: F1=1.00



B2 Full: F1=0.80



B2 Fewshot: F1=0.92

可视化说明

绿色填充 = SAM2 分割 mask; 红色框 = GT bbox。B1 (2592×1944, 大目标) 完美检测。B2 (4000×3000, 小目标) 全量训练有 3 个 FP。B2 fewshot (B1 checkpoint + 3 张微调) 仅 1 个 FP, 优于全量训练。

鼠肝 v2: 联邦学习四组策略

FL 策略对比 (YOLOv12n, 10 rounds $\times$ 10 local epochs)

Tag	Gate	Order	Final mAP50	Final mAP50-95	Best mAP50-95	Best@Rd
F1	none	b1→b2→b3	0.30	0.24	0.26	R3
F2	soft (EWA)	b1→b2→b3	0.75	0.47	0.47	R10
F3	hard	b1→b2→b3	0.92	0.62	0.62	R5
F4	hard	b3→b2→b1	0.91	0.51	0.51	R10

F3 hard gate 赢家

- mAP50=0.92, mAP50-95=0.62
- R4 收敛后冻结 (hard gate 阻断后续更新)
- b1 先跑建立强基座

B2 修复前后 FL 对比

	修复前	修复后
F3	0.60	0.92
F4	0.10	0.91
F2	0.88	0.75

鼠肝 v2: FL 收敛曲线

逐轮 mAP50 变化

	R1	R2	R3	R4	R5	R6	R7	R8	R9	R10
F1 (none)	.28	.32	.33	.31	.31	.28	.28	.30	.30	.30
F2 (soft)	.28	.32	.35	.35	.35	.58	.65	.67	.72	.75
F3 (hard)	.37	.31	.74	.92	.92	.92	.92	.92	.92	.92
F4 (hard)	.31	.54	.71	.84	.84	.84	.84	.86	.86	.91

F3 hard gate: R4 跳跃

- R3→R4: 0.74→0.92 (+18pp 跳跃)
- R4 后完全冻结
- hard gate = 只接受优于当前的更新

F2 soft gate: 平滑收敛

- R5→R6: 0.35→0.58 (开始加速)
- R10 仍在上升 (未收敛)
- soft gate = EWA 加权聚合

MultiOrg 扩展实验

Ensemble 实验: RF-DETR + YOLOv12

三种融合策略结果

策略	mAP50	mAP50-95	vs RF-DETR
RF-DETR 单模型	77.8%	48.8%	—
YOLOv12s 单模型	62.3%	37.2%	−15.5pp
WBF (SOTA 融合)	63.2%	38.3%	−14.5pp
Intersection	63.1%	39.7%	−14.7pp
Union	70.0%	42.8%	−7.8pp

失败原因: YOLOv12s 是严格劣势模型

- YOLO recall 80.4% $\ll$ RF-DETR 96.2%, 无独有 TP
- Ensemble TP=4745 < RF-DETR TP=4767 $\rightarrow$ YOLO 未补充任何 recall
- WBF 的 T/N 机制反而拉低 RF-DETR 高分 TP 的 score
- 结论: ensemble 需要两个精度接近的模型才能受益

全面文献调研: MultiOrg SOTA

MultiOrg 数据集 SOTA (mAP@0.5, t1_b)

方法	来源	mAP50
SSD	MultiOrg 论文 SOTA	73.9%
YOLOv3	MultiOrg 论文	70.3%
Faster R-CNN	MultiOrg 论文	68.4%
RF-DETR (我们)	本研究	77.8%

其他 organoid 数据集 SOTA

方法	mAP50	数据集	数据量
Deliod	87.5%	Intestinal	—
Orga-Dete	81.4%	Lung	4008 张
Orga-Dete	92.5%	Duodenal	—
Orga-Dete	84.4%	Murine intestinal	—
OrgLine	N/A (PQ)	Multi-source	—

结论：三模块全面失败，停止该方向

配置	mAP50	vs baseline	结论
yolo12s baseline	62.3%	—	参考
yolo11n + MPCA	44.2%	—	容量瓶颈
yolo11n + MPCA + EMASlideLoss	44.0%	-0.2pp	噪声级
yolo12s + MPCA (random init)	43.5%	-18.8pp	破坏预训练
yolo12s + MPCA (identity init)	43.9%	-18.4pp	init 不是根因
yolo12s + MPCA (identity) + EMASlideLoss	44.5%	-17.8pp	噪声级

MPCA Identity Init 修复 (commit 0cd3169)

- 问题：Sigmoid 随机初始化 $\approx 0.5 \rightarrow$ 特征方差减半 $\rightarrow$ 破坏预训练
- 修复：weight=0, bias=5 $\rightarrow \text{sigmoid}(5) \approx 1.0 \rightarrow \text{output} \approx x$ (identity)
- 验证：std ratio 0.50 $\rightarrow$ 0.99, 预训练匹配 48.6% $\rightarrow$ 99.2%
- 但 mAP 几乎不变 (+0.38pp) ——init 不是根因

模型容量 vs mAP 强相关

模型	mAP50
RF-DETR small (32M)	77.8%
YOLOv12s (9.4M)	62.3%
YOLOv11n+MPCA (2.6M)	44.2%
YOLOv12s+MPCA (9.6M)	43.9%

每 3.5x 参数 $\approx$ +18pp

五个根因

- ① 模型容量瓶颈：2.6M vs 32M
- ② MPCA 架构不兼容：C3k2 vs A2C2f
- ③ 单类检测无增益：坐标注意力对多类有用
- ④ 数据集差异：4008 张 vs 411 张
- ⑤ BiFPN 未验证：YAML 不兼容

铁律：乘性 Attention 必须 Identity Init

任何加在预训练模型上的乘性 attention 模块 (SE、CBAM、CA、MPCA)，初始状态必须是 identity，否则 sigmoid $\approx$ 0.5 会破坏预训练特征。验证方法：output/input std ratio $\approx$ 1.0。

联邦学习

EWA 熵加权聚合策略

核心思想

传统 FedAvg 按样本量均匀加权，忽略客户端模型质量差异。

EWA 用验证集熵作为信号，给更好的客户端更高权重：

$$w_c = \frac{\exp(-H_c/\alpha)}{\sum_{c'} \exp(-H_{c'}/\alpha)}$$

其中 H_c 是客户端 c 在验证集上的预测熵， α 是温度参数。

EWA Effective Interval 理论

- IID：质量差异小 $\rightarrow$ EWA 退化 $\rightarrow$ 无优势
- 适度异质：差异可区分 $\rightarrow$ EWA 最优 $\rightarrow +1.4\sim 1.5pp$
- 极端异质：信号噪声大 $\rightarrow +1.1pp$

视觉原语方案

视觉原语框架：范式转换

动机：bbox 范式到天花板

- bbox 对不规则类器官只能参考定位，不能做分类判断
- SAHI / NMS / Soft-NMS 都是后处理治标
- 需要范式转换，不是渐进优化

视觉原语框架

阶段	输入	输出
1. 检测	原图	bbox (RF-DETR)
2. 分割	bbox + 原图	无类别 mask (SAM2 zero-shot)
3. 形态学	mask	primitive 向量 (面积/圆度/solidity)
4. 语义确认	mask + 原图	VLM 推理 (是/否 organoid)
5. FL 聚合	primitive 分布	全局 primitive 分布

核心思想

FL 聚合的不是模型权重，而是 **primitive 分布**。形态学特征不受像素尺度、成像设备影响。

视觉原语方案：技术路线

Step 1-2: 检测 + 分割（已完成）

- RF-DETR: bbox 检测
- SAM2 zero-shot: mask 分割
- 鼠肝 B1: F1=1.00, mask F1=93.9%

Step 4: VLM 语义确认

- VLM 判断 mask 区域
- “这是类器官吗?”
- 保留不确定性

Step 3: 形态学特征

- 面积/周长/圆度
- Solidity/Extent
- 长宽比/离心率

Step 5: FL 聚合分布

- 各 client primitive 直方图
- 全局 = 加权聚合
- 不共享权重，共享知识

预期优势

不受像素尺度影响 → 跨域泛化；保留不确定性 → 避免强制决策；FL 聚合分布 → 隐私保护

CTM 持续思考实验

CTM: 连续思维机器 (Sakana AI, NeurIPS 2025)

核心创新

- **NLMs**: 每个神经元有私有权重 (非共享)
- **神经同步化**: 时间相关性矩阵 (非快照), Q 从同步化来
- **Attention Q 从内部来**: 模型自己决定看哪里 (emergent active vision)
- **Loss**: $\text{argmin}(\text{loss}) + \text{argmax}(\text{certainty}) \rightarrow$ 自适应计算

架构

- DINOv2 ViT-B/14 冻结 (86.6M params, 0 trainable)
- CTM head 可训练 (4.68M params)
- 输入 $224 \times 224 \rightarrow 257$ spatial tokens $\rightarrow 20$ ticks 推理

CTM 全量训练结果 (16198 crops, 50 epochs)

Test set 2445 samples (按图像分割, 0 泄露)

指标	AUC	说明
RF-DETR baseline	0.893	confidence 分数
CTM final tick	0.800	第 20 tick
CTM best tick	0.801	tick 17
CTM certain tick	0.800	argmax certainty per sample

CTM 没超过 RF-DETR baseline (差 8.7pp)

- Tick 1-2 AUC=0.20 (反预测), tick 3 突跳 0.79
- 之后 15 tick 只涨 0.8pp —“thinking” 效果极弱
- Certainty 全程 <0.37, 没有样本达到 0.8 阈值—自适应计算未启动

CTM 代码审计：5 个 Bug 修复

数据泄露 (Critical)

按检测索引分割 train/val/test → 同图 crops 跨 split

修复：按 **image_name** 分割 → 0 泄露

效果：62 样本 val 0.907 → 2445 样本 test 0.800 (水分 -10pp)

同步化零值污染 (Critical)

post_acts_history 预分配全零，每 tick 同步化混入当前 tick 的 0 值

→ 破坏时间相关性矩阵

修复：改为 growing list，action synch 只看过去，output synch 看过去 + 当前

其他修复

- `acc_best = acc_certain` 始终相同 (都用 final tick) → 分别用 `argmin/argmax`
- `auc_certain = auc_final` (`certain_probs` 算了没存) → 独立存储
- `generate_crops` 重跑时 `metadata` 为空 → 已存在 crop 也加 `metadata`

视觉原语文献调研

文献调研：关键论文发现

核心论文

论文	会议	贡献
FORLA	NeurIPS 2025	联邦 slot attention, 无监督跨域表征
TwVP	2025	点/bbox 作为推理链中的空间原语
WIPES	ICCV 2025	小波频域视觉原语
Neuro-Symbolic	AAAI 2025	混合 CV + 逻辑推理消歧
CZSL Survey	2025	属性 $\times$ 物体原语组合泛化

核心洞察

- 当前 TP/FP 在全局特征空间不可分 (DINOv2 PR-AUC=0.29)
- 需要换一个特征空间: **object-centric 分解** (slot attention)
- FORLA 直接命中: FL + object-centric + slot attention

Phase 8-11 实验设计

新增 4 个实验阶段

Phase	方法	假设	成本
8	小波频域 (WIPES)	TP/FP 频域可分	零 (CPU 30min)
9	Slot Attention (FORLA)	object-centric 分解可分	GPU 4-8h
10	联邦原语聚合	分布聚合 > 参数聚合	2-3 天代码
11	对比原语学习	InfoNCE 强制拉开 TP/FP	1 周

决策树

Phase 8 PR-AUC > 0.60 → 有效, 进 Phase 9 提升

Phase 8 < 0.50 → 无效, 直接进 Phase 9 换特征空间

Phase 9 > 0.50 → slot 有效, 进 Phase 10 联邦

Phase 9 < 0.50 → 进 Phase 11 对比学习

Phase 8 小波实验结果

Phase 8: 小波频域原语分析 (全量 16198 crops)

实验结果

实验	特征空间	PR-AUC	ROC-AUC	维度
DINOv2 CLS (之前)	768 维全局 embedding	0.29	—	768
形态学 (之前)	circ/solidity/ar	<0.50	—	4
W1: Haar 2L	28 维小波统计	0.457	0.681	28
W2: db4 3L	40 维小波统计	0.446	0.687	40
W3: haar+morph	32 维拼接	0.645	0.791	32
RF-DETR baseline	confidence	0.819	0.893	1

假设被推翻：小波单独无效

- PR-AUC $0.45 < 0.50$ (随机), 100 crops 小样本 inflated 了结果
- 每个单特征 PR-AUC 都 < 0.40 (LL_std=0.367 反预测)
- W3 morph 补救了 (+18.8pp), 说明形态学 + 小波有互补性
- 但仍远低于 RF-DETR 0.819

Phase 9 Slot Attention 结果

Phase 9: Slot Attention 原语提取 (FORLA 路线)

架构

- DINOv2 ViT-B/14 冻结 (86.6M params, 0 trainable)
- Slot Attention: $K=8$ slots, $\text{dim}=128$, 3 iters
- 可训练参数: 480K (CTM 4.68M 的 1/10)
- 输入 $224 \times 224 \rightarrow$ DINOv2 spatial tokens $[257, 768] \rightarrow$ Slot Attention $\rightarrow 8$ slots $[8, 128] \rightarrow$ classifier

训练 (16198 crops, 50 epochs, 冬生 3060)

- Train: 6316 (3158TP + 3158FP, balanced)
- Val: 2409 (666TP + 1743FP), Test: 2445 (805TP + 1640FP)
- 128s/epoch, early stop ep36 (patience=15)
- Best val AUC: 0.890 (ep21) $\approx$ RF-DETR 0.883

Phase 9: Slot Attention 全方案对比

Test set 结果 (2445 samples)

方法	特征空间	ROC-AUC	PR-AUC	vs RF-DETR
RF-DETR confidence	1 维	0.888	0.828	baseline
Slot Attention	8×128=1024 维	0.868	0.788	-2.0pp
CTM (20 ticks)	4.68M	0.800	—	-8.8pp
W3 haar+morph	32 维	0.791	0.645	-9.7pp
Phase 5 k-NN (形态学)	6 维	0.739	—	-14.9pp
W1 haar 2L	28 维	0.681	0.457	-20.7pp
VLM (100 crops)	LLM 评分	0.713	—	-17.5pp
DINOv2 CLS	768 维	—	0.29	-53.8pp

关键发现

- Slot Attention 是所有替代方案中最强的 (-2.0pp vs RF-DETR)
- Val AUC 0.890 $\approx$ RF-DETR 0.883 —val 上几乎追平
- 过拟合轻: train acc ep36=0.878 (CTM ep2=1.0)
- 480K params, 极轻量

Phase 9: 决策树与下一步

决策树结果

Phase 8 小波 PR-AUC = $0.45 < 0.50$ → 频域无效

Phase 9 Slot PR-AUC = **0.788** > **0.50** → **object-centric** 分解有效!

缺失实验 (高优先级)

- **Slot + confidence 组合 AUC**: 如果互补, combined 可能 > 0.888
- **Phase 11 对比学习**: InfoNCE 强制拉开 TP/FP → 目标 PR-AUC > 0.85
- **Phase 10 联邦 slot 聚合**: FORLA + FedCtx HNSW

为什么 Slot Attention 有效?

- DINOv2 CLS = 全局 embedding, TP/FP 完全重叠 (PR-AUC=0.29)
- Slot Attention = object-centric 分解, 每个 slot 学一个物体组件
- TP 有 organoid 内部纹理结构 → slot 捕获
- FP 是背景碎片 → slot 不同

Phase 11 SupCon + C4 闭环

Phase 11: SupCon 对比学习 (β 消融)

$$\text{Loss} = \text{CE} + \beta \times \text{SupCon}$$

- SupCon (Khosla NeurIPS 2020): TP-TP embedding 拉近, TP-FP 推远
- Projection head: 128 $\rightarrow$ 256 $\rightarrow$ L2 normalize
- $\beta = 0.5$: SupCon 贡献 1.6 = CE 的 3x $\rightarrow$ 压制分类头
- $\beta = 0.1$: SupCon 贡献 0.32 $\rightarrow$ CE 主导, SupCon 辅助

β 消融结果 ($\tau = 0.07$ 固定)

指标	Phase 9	$\beta = 0.5$	$\beta = 0.1$
Slot AUC	0.868	0.845	0.860
Embedding AUC	—	0.859	0.868
Combined AUC	0.903	0.909	0.910
Combined PR-AUC	0.853	0.860	0.862
Val best AUC	0.890	0.917	0.922

C4 闭环验证: Slot 过滤提升检测 AP

实验设计 (方案 §7.6)

- 用 SupCon 训练的 slot encoder 对 RF-DETR 检测框打分
- 4 种过滤策略搜索最优参数
- 评估指标: PR-AUC (=AP50 近似)

结果 ($\beta = 0.1$ embeddings)

策略	AP	Δ AP	参数
Baseline (RF-DETR conf)	0.829	—	—
Hard filter	0.834	+0.5pp	thr=0.10
Soft penalize ($\alpha=0.5$)	0.860	+3.1pp	$\text{conf} \times (1 - 0.5(1 - s))$
Geometric mean	0.861	+3.3pp	$\text{conf}^{0.8} \times \text{slot}^{0.2}$
LR meta (5-fold)	0.857	+2.9pp	5-fold LR

结论

RF-DETR AP 0.829 $\rightarrow$ 0.861 (+3.3pp)

最优权重 $w_{\text{slot}} = 0.20$ (和 Phase 9 组合分析一致)

Phase 10: 联邦 Slot 聚合 (真 Plate $\times$ Class)

6 个真实 client

Client	N	TP%	Local	Global	Δ	Conf
Macros_P23	328	23%	0.697	0.754	+5.7pp	0.891
Normal_P31	207	28%	0.792	0.830	+3.8pp	0.900
Normal_P37	283	17%	0.836	0.830	-0.6pp	0.915
Macros_P4	772	40%	0.821	0.810	-1.1pp	0.874
Normal_P15	597	39%	0.890	0.887	-0.3pp	0.919
Normal_P4	258	33%	0.896	0.885	-1.0pp	0.903
Mean	—	—	0.822	0.833	+1.1pp	0.900

关键洞察

- 小 client / 低 TP 率获益最大 (Plate_23 +5.7pp)
- 大 client 不获益 (本地数据已足够)
- Combined (kNN+conf) ROC=0.907 (+1.9pp vs RF-DETR)
- “数据不动，知识动”：只共享 256 维 embedding

跨域泛化: MultiOrg $\rightarrow$ 鼠肝 & Intestinal (结果)

实验设置

- SupCon checkpoint: MultiOrg 100 crops 训练 ($K=8$, $\text{dim}=128$, $\tau=0.07$, $\beta=0.1$)
- 评估: DINOv2 ViT-B/14 提取 embedding $\rightarrow$ slot attention $\rightarrow$ AUC/AP
- 鼠肝: RF-DETR Small 检测 (3 batch checkpoint), Intestinal: YOLOv12s 检测

DINOv2 跨域结果: Slot 失效 + LOO 真跨域

数据集	单域	同域	LOO	Conf	泄露
鼠肝 B1	0.29	0.74	0.49	0.91	0.25
鼠肝 B2	0.51	0.70	0.56	0.98	0.14
鼠肝 B3	0.54	0.85	0.82	0.92	0.03
Intestinal	0.67	0.74	0.58	0.92	0.16

诊断

- 同域结果有数据泄露 (平均虚高 0.14pp)
- LOO 真跨域: B1/B2 接近随机, Intestinal 比单域还差
- 根因: DINOv2 全局特征是域特定的, 不构成通用 organoid 原语

CLIP 语义对齐: Zero-Shot 跨域有信号

动机: 借鉴 NLP 语义分析成功经验

- NLP 跨域成功 = 大规模预训练 + 语义对齐 + CoT 推理
- DINOv2 有预训练但**无语义对齐**——纯视觉特征域特定
- CLIP 有文本-视觉对齐空间 → “a real organoid” vs “background”

CLIP Zero-Shot 结果 (无训练!)

数据集	DINOv2 单域	DINOv2 LOO	CLIP zero-shot	Conf
MultiOrg	0.79	—	0.73	0.87
鼠肝 B1	0.29	0.49	0.86	0.91
鼠肝 B2	0.51	0.56	0.66	0.98
鼠肝 B3	0.54	0.82	0.69	0.92

关键发现

- B1 从 0.29 → **0.86** (+0.57), zero-shot 差 conf 仅 5.8pp
- CLIP **无需训练**, 仅用文本 prompt 就能跨域区分 TP/FP
- “morphological” prompt 在鼠肝最优, “medical” 在 MultiOrg 最优

训练破坏泛化：SupCon / CoOp LOO 结果

所有监督训练都破坏 CLIP zero-shot 跨域能力

数据集	DINOv2 LOO	CLIP zero-shot	CLIP+SupCon	CoOp	Conf
MultiOrg	—	0.73	0.95	0.62	0.87
鼠肝 B1	0.49	0.86	0.50	0.67	0.91
鼠肝 B2	0.56	0.66	0.57	0.58	0.98
鼠肝 B3	0.82	0.69	0.45	0.65	0.92
Intestinal	0.58	0.69	0.50	0.69	0.92
平均	0.58	0.73	0.58	0.64	0.94

核心结论

- CLIP zero-shot (无训练) = 最强跨域 slot (平均 0.73)
- SupCon 训练 slot → B1 从 0.86 → 0.50 (-0.36)
- CoOp 训练 prompt → B1 从 0.86 → 0.67 (-0.19, 破坏更少但仍不如 zero-shot)
- 和 NLP 一致：微调破坏预训练 zero-shot 泛化
- → 不训练参数，改用 prompt 工程 / VLM 推理 / 3D 时序

总结

总结

已完成

- ✓ SOTA 全面调研 + MultiOrg 77.8%
- ✓ SAM2 三轮 + FP 抑制 + Ensemble 均失败
- ✓ 鼠肝 v2 14 实验 + bbox FL 完成
- ✓ CTM 全量训练: AUC=0.80 (<RF-DETR)
- ✓ Phase 8 小波: 假设被推翻
- ✓ Phase 9 Slot: PR-AUC=0.788
- ✓ Phase 9 组合: AP 0.903 (+1.5pp)
- ✓ Phase 11 SupCon $\beta = 0.1$: AP 0.910
- ✓ C4 闭环: AP 0.829→0.861 (+3.3pp)
- ✓ Phase 10 联邦: Global>Local +1.1pp
- ✓ 视觉原语文献调研 (FORLA/TwVP/WIPES)
- ✓ 跨域评估: 4 场景全部失效
- ✓ LOO 真跨域: DINOv2 仍然失败

核心成果

- RF-DETR AP: 0.829 → **0.861** (+3.3pp)
- Combined ROC: **0.910** (+2.2pp)
- 联邦聚合: 小 client +5.7pp
- **DINOv2 跨域失效**, CLIP 语义对齐有效
- 所有训练都破坏 zero-shot 泛化
- CLIP zero-shot 平均 0.73 = 最强跨域

未来工作：数据集扩展计划

已使用数据集

数据集	张数	类型	状态
Intestinal (Deliod)	—	肠道类器官	✓超 SOTA 88.1%
鼠肝 B1/B2/B3	40	鼠肝类器官	✓完成
MultiOrg	411	多类器官	✓超 SOTA 77.8%

计划扩展数据集

数据集	特点	目标
肠/肺/脑类器官	不同器官类型	跨器官泛化
多实验室鼠肝	不同显微镜/染色	预处理标准化
多倍率 (4X/10X/20X)	分辨率差异	尺度不变性
共聚焦/荧光	不同成像方式	跨模态 FL

核心方向

预处理标准化 → 视觉原语 → FL 聚合 → 数据飞轮

参考文献 I



Bukas et al. *MultiOrg: A Multi-rater Organoid-detection Dataset*. NeurIPS, 2024.



Tian et al. *YOLOv12: Attention-Centric Real-Time Object Detectors*. arXiv:2502.12524, 2025.



Solawetz et al. *RF-DETR: Real-Time DETection TRansformer*. ICLR, 2026.



Bodla et al. *Soft-NMS – Improving Object Detection with One Line of Code*. ICCV, 2017.



Akyon et al. *Slicing Aided Hyper Inference (SAHI)*. CVPRW, 2022.



Bulten et al. *Overcoming the Limitations of Patch-based Learning to Detect Cancer in Whole Slide Images*. PMC, 2021.



Lu et al. *Thinking with Visual Primitives*. DeepSeek-AI, 2025.



Kirillov et al. *Segment Anything (SAM)*. ICCV, 2023.



Solovyev et al. *Weighted Boxes Fusion: Ensembling boxes from different object detection models*. IVC, 2021.



Huang et al. *Orga-Dete: An Improved Lightweight Deep Learning Model for Lung Organoid Detection*. Applied Sciences, 2025.



Deng et al. *OrgLine: A versatile pipeline for organoid morphometry using detector-guided prompts*. Cell Reports Methods, 2026.

Thank You!

Questions & Discussion

`github.com/dechang64/organoid-fl`